

Universidad Nacional de Ingeniería

Facultad de Ingeniería Económica, Estadística y Ciencias Sociales

Unidad de Posgrado

Tesis doctoral

Estimación de efectos causales en datos observacionales mediante doble aprendizaje automático

Para optar el grado académico de

Doctor en Ciencias e Ingeniería Estadística

Presentado por

Nombre del Autor

Asesor

Dr. Nombre del Asesor

Lima — Perú

2026

Dedicatoria

A quienes preguntan «¿y por qué?» antes que «¿para qué?»: a mis maestros, que convirtieron la curiosidad en método, y a mi familia, que sostuvo cada página de este camino.

Agradecimientos

A mi asesor, por la exigencia rigurosa y la generosidad intelectual con que orientó cada etapa de esta investigación; a los integrantes del Grupo de Estudio de Inferencia Causal de la Universidad Nacional de Ingeniería, cuyo seminario semanal dio origen a las preguntas que aquí se desarrollan; y a la Unidad de Posgrado de la Facultad de Ingeniería Económica, Estadística y Ciencias Sociales, por el espacio académico y el apoyo institucional recibidos.

Agradezco igualmente a los revisores anónimos, cuyas observaciones mejoraron sustancialmente la presentación de los resultados, y a la comunidad de software libre, en cuyas herramientas —Python, NumPy y scikit-learn— se apoya íntegramente la parte computacional de este trabajo.

Resumen

Esta tesis desarrolla y evalúa un marco para la estimación de efectos causales a partir de datos observacionales cuando las relaciones entre las covariables, el tratamiento y el resultado son desconocidas y potencialmente no lineales. El marco combina el principio de parcialado (**partialling-out**) con aprendices flexibles de potenciación de gradiente por histogramas y validación cruzada, en el espíritu del doble aprendizaje automático (DML), y se contrasta sistemáticamente con la diferencia de medias, la ponderación por probabilidad inversa (IPW) y el ajuste lineal por mínimos cuadrados ordinarios.

Los experimentos de simulación, calibrados con un confusor no lineal, una covariable de colas pesadas y un tamaño de efecto conocido ($\tau = 2$), muestran que el ajuste lineal incurre en un sesgo persistente cercano a $+0.95$ aun con $n = 5000$ observaciones, mientras que el estimador DML reduce su sesgo de $+0.258$ (con $n = 250$) a $+0.003$ (con $n = 5000$) y alcanza la menor raíz del error cuadrático medio en todos los escenarios. La cobertura de los intervalos construidos con la función de influencia se aproxima al nivel nominal del 95 % a medida que crece el tamaño de muestra, en tanto que la cobertura del ajuste lineal colapsa a 0 % porque el error estándar decrece más rápido que el sesgo. La distribución bootstrap del estimador de ajuste lineal, estrecha pero centrada lejos del valor verdadero, ilustra que la precisión no compensa la ausencia de validez causal.

Palabras clave: inferencia causal, doble aprendizaje automático, propensión al tratamiento, datos observacionales, validación cruzada.

Abstract

This thesis develops and evaluates a framework for estimating causal effects from observational data when the relationships among covariates, treatment, and outcome are unknown and potentially nonlinear. The framework combines the partialling-out principle with flexible histogram gradient-boosting learners and cross-fitting, in the spirit of double machine learning (DML), and is systematically compared against the difference-in-means estimator, inverse probability weighting (IPW), and ordinary least squares adjustment.

Monte Carlo experiments calibrated with a nonlinear confounder, a heavy--tailed covariate, and a known effect size ($\tau = 2$) show that linear adjustment incurs a persistent bias of about $+0.95$ even with $n = 5000$ observations, whereas the DML estimator reduces its bias from $+0.258$ (at $n = 250$) to $+0.003$ (at $n = 5000$) and attains the lowest root mean squared error in every scenario. Confidence intervals built from the influence function approach the nominal 95 % level as the sample size grows, while the coverage of linear adjustment collapses to 0 % because its standard error shrinks faster than its bias. The bootstrap distribution of the linear-adjustment estimator—narrow yet centered away from the true value—illustrates that precision is no substitute for causal validity.

Keywords: causal inference, double machine learning, propensity score, observational data, cross-fitting.

Copia de Documentos

En esta sección se incorporan los documentos exigidos por la Unidad de Posgrado: cartas, actas, formatos y constancias. Sustituya el presente texto por los documentos correspondientes. El formato de portada, márgenes y entrega se rige por el **Formato de Presentación de Tesis de la UNI** y las directivas vigentes de la FIEECS (véase la biblioteca de enlaces del repositorio, carpeta `documentacion/06-biblioteca-enlaces.md`).

> **Instrucciones**
>
> Para insertar un documento digitalizado, colóquelo en la carpeta `documentos/` e inclúyalo con `#figure(image("documentos/acta.pdf", width: 92%), caption: [Acta de aprobación del proyecto])`. La plantilla se encarga del estilo del pie de figura.

Índice general

Dedicatoria ..... **i**
Agradecimientos ..... **ii**
Resumen ..... **iii**
Abstract ..... **iv**
Copia de Documentos ..... **v**
1 Introducción **1**
1.1 Motivación y contexto 1
1.2 Planteamiento del problema 1
1.3 Objetivos 2
1.4 Hipótesis y variables 3
1.5 Justificación 3
1.6 Estructura de la tesis 4
2 Marco teórico **5**
2.1 Antecedentes 5
2.2 Fundamentos matemáticos 5
2.3 Definición de términos 8
2.4 Tabla de notación causal 8
2.5 Estado del arte 9
3 Metodología **10**
3.1 Diseño de la investigación 10
3.2 Población, muestra y fuente de datos 10
3.3 Procedimiento y plan de análisis 10
3.4 Técnicas estadísticas 11
3.5 Implementación computacional 12
4 Resultados **14**
4.1 Análisis descriptivo 14
4.2 Inferencia estadística 14
4.3 Análisis de sensibilidad 17
4.4 Validación del modelo 17
5 Discusión **19**
6 Conclusiones y recomendaciones **20**
6.1 Conclusiones 20
6.2 Recomendaciones 20
6.3 Limitaciones 21

6.4 Líneas futuras de investigación 21
Referencias bibliográficas 22
A Apéndice de reproducibilidad 24
B Matriz de consistencia 25
C Matriz de operacionalización de variables 27
D Demostraciones técnicas 28
E Código fuente 29
F Datos suplementarios 30

Índice de figuras

Figura 2.1 Grafo dirigido acíclico de la confusión: el confusor C abre un camino espurio entre el tratamiento A y el resultado Y. **6**

Figura 4.1 Cobertura empírica de los intervalos al 95 % según el tamaño de muestra; la línea discontinua marca el nivel nominal. **16**

Figura 4.2 Distribución bootstrap ($B = 2000$) del estimador de ajuste lineal con $n = 1000$: el intervalo percentil al 95 % excluye a $\tau = 2$. **17**

Índice de tablas

Tabla 2.1 Notación causal y de estimación. 8
Tabla 3.1 Supuestos de identificación y amenaza dominante por estimador en el diseño Monte Carlo. 11
Tabla 4.1 Estadísticos descriptivos del conjunto de referencia ($n = 1000$). . 14
Tabla 4.2 Sesgo, raíz del error cuadrático medio (RMSE), error estándar medio (EE) y cobertura empírica al 95 %: el sesgo de la diferencia de medias y del ajuste lineal es estable en n, no decrece con la muestra. 15
Tabla 4.3 Sensibilidad al recorte de propensidad (IPW) y a la especificación lineal ($\tau = 2$, $n = 1000$, $B = 80$). Cifras en `results.json` → `sensibilidad`. . 17
Tabla B.1 Matriz de consistencia de la investigación. 26
Tabla C.1 Matriz de operacionalización de variables. 27
Tabla F.1 Parámetros del diseño experimental del estudio Monte Carlo. . 30

Capítulo 1

Introducción

1.1 Motivación y contexto

Las decisiones públicas más importantes —qué programa social ampliar, qué tratamiento priorizar, qué política descontinuar— dependen de responder una pregunta contrafactual: ¿qué habría ocurrido si el individuo no hubiera recibido la intervención? Cuando la aleatorización es inviable por razones éticas o presupuestales, la respuesta debe construirse a partir de datos observacionales, en los que la asignación del tratamiento depende de las características mismas de las unidades estudiadas. Esa dependencia es la fuente del sesgo de confusión, y controlarla exige suposiciones sobre la forma funcional con que las covariables entran en el proceso de asignación y en el resultado.

En paralelo, las últimas décadas han consolidado aprendices estadísticos de alta flexibilidad —bosques aleatorios (Breiman, 2001), redes neuronales (LeCun et al., 1998) y métodos de regularización (Tibshirani, 1996; Zou & Hastie, 2005) — capaces de aproximar funciones de regresión arbitrariamente irregulares. La flexibilidad, sin embargo, no es gratuita: los errores de estimación de esas funciones «nuisance» se trasmiten al estimador del efecto causal y contaminan su distribución límite. La pregunta central de esta tesis es cómo conciliar ambas demandas: la flexibilidad necesaria para ajustar confusión no lineal y la disciplina inferencial que exige un intervalo de confianza honesto.

1.2 Planteamiento del problema

El problema puede formularse con precisión. Sea $A \in \{0, 1\}$ un tratamiento binario, Y una respuesta continua y X un vector de covariables observadas antes del tratamiento. Bajo el supuesto de no confusión no observada, el efecto promedio del tratamiento

$$\tau = E[Y(1)] - E[Y(0)] \tag{1.1}$$

es identificable a partir de la distribución observable de (X, A, Y). Los estimadores clásicos lo explotan bajo restricciones que rara vez se satisfacen en la práctica:

el ajuste por regresión supone formas lineales para las funciones de resultado, y la ponderación por probabilidad inversa supone un modelo de propensión correctamente especificado. Cuando el confusor actúa de manera no lineal, ambos enfoques fallan de manera sistemática y silenciosa: el error estándar disminuye con la muestra, pero el sesgo permanece, de modo que la cobertura de los intervalos de confianza se deteriora precisamente cuando el investigador tiene más motivos para confiar en ellos.

De ese diagnóstico surgen las preguntas de investigación que guían el trabajo:

- ¿Bajo qué condiciones sobre los aprendices de las funciones nuisance un estimador de τ construido por parcialado preserva la validez asintótica?
- ¿Cuál es el costo, en sesgo y cobertura, de ajustar la confusión no lineal con modelos lineales mal especificados?
- ¿Cómo se comparan, en escenarios calibrados con confusores no lineales y colas pesadas, la diferencia de medias, la ponderación por probabilidad inversa, el ajuste lineal y el doble aprendizaje automático?

1.3 Objetivos

1.3.1 *Objetivo general*

Desarrollar y evaluar, mediante simulación Monte Carlo con un generador de datos calibrado, un marco de estimación de efectos causales en datos observacionales que combine el parcialado con aprendices flexibles y validación cruzada, y contrastar su sesgo, su error cuadrático medio y la cobertura de sus intervalos con los de los estimadores clásicos.

1.3.2 *Objetivos específicos*

1. Formalizar las condiciones de ortogonalidad y velocidad de convergencia que garantizan la validez asintótica del estimador por parcialado cuando las funciones nuisance se estiman con aprendices flexibles.
2. Diseñar e implementar un protocolo de simulación con confusor no lineal, covariable de colas pesadas y tamaño de efecto conocido, reproducible con semillas fijas.
3. Cuantificar el sesgo, la raíz del error cuadrático medio y la cobertura empírica de los cuatro estimadores en tamaños de muestra $n \in \{250, 1000, 5000\}$, y documentar el papel del bootstrap como diagnóstico de precisión frente a la validez.

1.4 Hipótesis y variables

1.4.1 *Hipótesis*

- **Hipótesis general:** bajo no confusión no observada y aprendices cuya velocidad de convergencia supere $n^{-\frac{1}{4}}$, el estimador de doble aprendizaje automático por parcialado es insensible en primer orden a los errores de estimación de las funciones nuisance, por lo que su sesgo es despreciable y su cobertura se aproxima al nivel nominal, aun cuando la confusión sea no lineal.
- **Hipótesis específicas:** (i) el ajuste lineal omiso del término no lineal del confusor conserva un sesgo que no decrece con n; (ii) la ponderación por probabilidad inversa es consistente pero vulnerable a la varianza de los pesos y al recorte de propensiones extremas; y (iii) la distribución bootstrap de un estimador sesgado converge a su valor sesgado, por lo que no constituye evidencia de validez causal.

1.4.2 *Variables y definiciones operacionales*

- **Variable dependiente (respuesta):** Y, resultado continuo generado como $Y = \tau A + m(X) + \varepsilon$ con $\varepsilon \sim N(0, 1.5^2)$.
- **Variable de tratamiento:** $A \in \{0, 1\}$, con propensidad $e(X) = P(A = 1 \texttt{ mid } X)$ no lineal en X_3.
- **Covariables:** $X = (X_1, ..., X_5)$; X_1, X_2 y X_3 son confusores (afectan a A y a Y), mientras que X_4 y X_5 son ruido puro; X_2 sigue una distribución t de Student con 3 grados de libertad estandarizada.
- **Parámetro de interés:** $\tau = 2$, el efecto promedio del tratamiento en la población.

1.5 Justificación

Justificación teórica. El trabajo articula dos literaturas que suelen transitar separadas: la teoría de la estimación semiparamétrica, que establece condiciones de ortogonalidad tipo Neyman, y la práctica del aprendizaje estadístico moderno (Hastie et al., 2015). Explicitar esa articulación en un solo marco verificable contribuye a la formación de estadísticos capaces de usar herramientas flexibles sin renunciar a la inferencia.

Justificación metodológica. El protocolo de simulación —con generador calibrado, semillas fijas y métricas estandarizadas de sesgo, RMSE y cobertura — es íntegramente reproducible y puede reutilizarse como banco de pruebas para nuevos estimadores causales, en la tradición del remuestreo introducido por (Efron, 1979).

Justificación práctica. En el Perú, la evaluación de programas sociales y de políticas públicas descansa crecientemente en registros administrativos de gran

volumen, cuya estructura de confusión es compleja y desconocida. Disponer de estimadores robustos a la mala especificación funcional, y de protocolos honestos para reportar su incertidumbre, tiene un impacto directo en la calidad de la evidencia usada para decidir.

1.6 Estructura de la tesis

El documento se organiza en seis capítulos y cinco apéndices. El capítulo 2 consolida los fundamentos matemáticos y el estado del arte. El capítulo 3 detalla el diseño metodológico, el generador de datos y los estimadores comparados, incluido el algoritmo de parcialado con validación cruzada. El capítulo 4 presenta los resultados descriptivos e inferenciales. El capítulo 5 discute los hallazgos y los pone en perspectiva con la literatura. El capítulo 6 concluye y recomienda. Los apéndices contienen la matriz de consistencia, la matriz de operacionalización, las demostraciones técnicas, el código fuente y los datos suplementarios del experimento.

Capítulo 2

Marco teórico

2.1 Antecedentes

La inferencia a partir de datos remuestreados tiene un hito fundacional en el trabajo de (Efron, 1979), quien formalizó el bootstrap como procedimiento general para aproximar la distribución de un estadístico sin apoyarse en derivaciones analíticas. Medio siglo después, el bootstrap sigue siendo el instrumento de diagnóstico por excelencia de la variabilidad estimada, y esta tesis lo emplea precisamente para mostrar sus límites: su capacidad de revelar la precisión de un estimador, y su impotencia para detectar el sesgo que hereda de una mala especificación.

En el frente del aprendizaje estadístico, (Tibshirani, 1996) introdujo el lasso y (Zou & Hastie, 2005) la red elástica, demostrando que la penalización puede convertir la estimación en altas dimensiones en un problema bien planteado; (Breiman, 2001) estableció que el agregamiento de árboles débilmente correlacionados reduce drásticamente la varianza sin sacrificar la adaptabilidad. Sobre esas bases se construyeron los aprendices flexibles que hoy alimentan los métodos de doble aprendizaje automático (Chernozhukov et al., 2018). Para los fundamentos de probabilidad e inferencia clásica, el trabajo se apoya en los tratados de (Casella & Berger, 2002) y (Wasserman, 2006).

2.2 Fundamentos matemáticos

La formalización requiere de tres piezas: el espacio probabilístico sobre el cual se definen los datos, el lenguaje de los resultados potenciales que da contenido al parámetro causal, y la teoría asintótica que valida los intervalos de confianza.

Definición 2.1 (Espacio de probabilidad). Un espacio de probabilidad es una terna $(\Omega, \mathcal{F}, P)$ donde Ω es el espacio muestral, $\mathcal{F}$ es una σ-álgebra sobre Ω y $P : \mathcal{F} \to [0, 1]$ es una medida de probabilidad.

Definición 2.2 (Resultados potenciales y efecto causal). Para cada unidad se definen los resultados potenciales $(Y(0), Y(1))$, el valor de la respuesta bajo cada nivel de tratamiento. El efecto promedio del tratamiento es la diferencia de expectativas

$$\tau = E[Y(1)] - E[Y(0)], \tag{2.1}$$

y el efecto observado corresponde a $Y = Y(A)$.

La identificación de τ a partir de datos observacionales exige supuestos sobre el mecanismo de asignación.

Definición 2.3 (Propensidad al tratamiento). La propensidad es la probabilidad condicional de recibir el tratamiento,

$$e(x) = P(A = 1 \texttt{ mid } X = x), \quad x \in \mathbb{R}^d. \tag{2.2}$$

Bajo no confusión no observada $(Y(0), Y(1)) \perp A \texttt{ mid } X$ y positividad $0 < e(x) < 1$, el parámetro τ es identificable, pues $E[Y \texttt{ mid } A = a, X = x]$ recupera $E[Y(a) \texttt{ mid } X = x]$. La estructura de la confusión se representa de manera compacta con grafos dirigidos acíclicos, como ilustra la Figura 2.1: el confusor C abre un camino espurio entre el tratamiento A y el resultado Y que el estimador ingenuo atribuye al efecto causal τ.

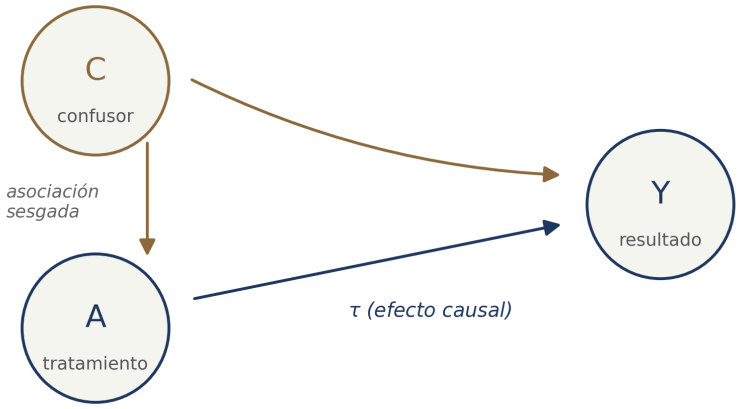


Figura 2.1. Grafo dirigido acíclico de la confusión: el confusor C abre un camino espurio entre el tratamiento A y el resultado Y.

La validez de los intervalos de confianza descansa, finalmente, en la teoría asintótica.

Teorema 2.4 (Teorema central del límite). *Sea $(X_n)_{n\geq 1}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas con $E[X_1] = \mu$ y $\mathrm{Var}(X_1) = \sigma^2 < \infty$. Entonces*

$$\frac{\sqrt{n}\left(\overline{X}_n - \mu\right)}{\sigma} \xrightarrow{d} N(0,1), \quad \overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i, \tag{2.3}$$

donde $\xrightarrow{d}$ denota convergencia en distribución.

Demostración. La demostración clásica procede por funciones características: la función característica de $\sqrt{n}\frac{\overline{X}_n - \mu}{\sigma}$ admite el desarrollo de Taylor $1 - \frac{t^2}{2n} + o(n^{-1})$, cuyo límite es $e^{-\frac{t^2}{2}}$, la función característica de la distribución normal estándar; el teorema de continuidad de Lévy concluye. El detalle completo se desarrolla en el apéndice C. ■

El estimador central de esta tesis se apoya en una propiedad de ortogonalidad que merece enunciarse con precisión.

Proposición 2.5 (Ortogonalidad del residual de Neyman). *Sean $\hat{m}(X)$ y $\hat{e}(X)$ estimaciones de la función de resultado no tratado $m(X) = E[Y \texttt{ mid } A = 0, X]$ y de la propensidad $e(X)$. Si ambas convergen en error cuadrático a velocidad $o_p\left(n^{-\frac{1}{4}}\right)$ y se construyen por validación cruzada, el estimador por parcialado*

$$\hat{\tau} = \frac{\sum_{i=1}^{n} \hat{A}_i \hat{Y}_i}{\sum_{i=1}^{n} \hat{A}_i^2}, \quad \hat{A}_i = A_i - \hat{e}(X_i), \quad \hat{Y}_i = Y_i - \hat{m}(X_i) \tag{2.4}$$

es insensible en primer orden a los errores de estimación de las funciones nuisance y satisface $\sqrt{n}(\hat{\tau} - \tau) \xrightarrow{d} N(0, V)$ con V determinada por la función de influencia.

Demostración. La clave es que el producto interno muestral de los residuales de A con los residuales de Y cancela, en expectativa, los términos de primer orden que involucran $\hat{m} - m$ y $\hat{e} - e$: la derivada direccional del funcional en la dirección de los errores nuisance es nula por la ortogonalidad de las proyecciones. La validación cruzada elimina el sesgo de sobreajuste que aparecería si los mismos datos sirvieran para ajustar y para evaluar. ■ (esbozo; el desarrollo completo sigue el argumento estándar del doble aprendizaje automático.) ■

Como se establece en la Definición 2.1, el marco de trabajo es un espacio de probabilidad; la Definición 2.3 define la propensidad que estimarán los métodos de ponderación; y la Proposición 2.5 garantiza que el Algoritmo 3.1 del capítulo 3 herede la normalidad asintótica del Teorema 2.4.

2.3 Definición de términos

Modelo estadístico: una familia de distribuciones $\mathcal{P}_\theta$, $\theta \in \Theta$, postulada para el mecanismo generador de los datos; la flexibilidad de la familia determina el riesgo de sesgo por mala especificación.

Estimación: el procedimiento que asigna a θ un valor $\hat{\theta}$ a partir de la muestra; sus propiedades relevantes aquí son el sesgo, la consistencia y la eficiencia asintótica.

Inferencia causal: el conjunto de técnicas que identifican y estiman efectos contrafactuales —del tipo $E[Y(1)] - E[Y(0)]$— a partir de datos observables, bajo supuestos de no confusión y positividad.

Doble aprendizaje automático: estrategia de estimación que emplea aprendices flexibles para dos funciones nuisance —el resultado esperado y la propensidad— y combina sus residuales de modo que los errores de ambos se cancelen en primer orden.

Validación cruzada: partición de la muestra en bloques que alternan el ajuste y la predicción, usada aquí para evitar el sesgo de sobreajuste en las funciones nuisance.

Cobertura empírica: proporción de réplicas de un experimento de simulación en las que el intervalo de confianza construido contiene al parámetro verdadero; su distancia al nivel nominal resume la honestidad del procedimiento inferencial.

2.4 Tabla de notación causal

La Tabla 2.1 fija los símbolos principales del documento (guía 03 del repositorio).

Tabla 2.1. Notación causal y de estimación.

Símbolo	Significado
$Y(0), Y(1)$	Resultados potenciales bajo $A = 0$ y $A = 1$
Y	Respuesta observada $Y = Y(A)$
A	Tratamiento binario
X	Covariables pre-tratamiento ($d = 5$ en la simulación)
$e(x)$	Propensión $P(A = 1 \texttt{ mid } X = x)$
$m(x)$	Resultado esperado sin tratamiento
τ	ATE $E[Y(1) - Y(0)]$ — estimando de interés
$\hat{\tau}$	Estimador (DM, IPW, OLS, DML)
ψ_i	Contribución a la función de influencia (DML)

2.5 Estado del arte

El marco de doble aprendizaje automático (**double/debiased machine learning**) formalizado por (Chernozhukov et al., 2018) combina estimación flexible de funciones nuisance, ortogonalidad del funcional del parámetro de interés y validación cruzada (**cross-fitting**) para obtener inferencia válida sobre efectos causales y parámetros estructurales en el régimen de alta dimensionalidad. La implementación de esta tesis sigue la variante DML2 del modelo parcialmente lineal descrito en ese trabajo.

La confluencia entre regularización e inferencia cristalizó en la pasada década. (Hastie et al., 2015) sistematizaron la estadística con esparsidad —el lasso y sus generalizaciones— y (Friedman et al., 2010) aportaron el algoritmo de descenso coordinado que hizo práctico el ajuste de rutas de regularización completas. La trama de la estimación causal flexible se completa con la arquitectura de aprendizaje por gradiente de (LeCun et al., 1998), hoy materializada en los aprendices de potenciación de gradiente por histogramas que utiliza esta tesis, y con la perspectiva bayesiana jerárquica de (Gelman, 2006), que recuerda que toda especificación —frecuentista o bayesiana— incorpora supuestos previos cuya sensibilidad debe examinarse.

El estado del arte puede resumirse en una lección: ningún aprendiz, por flexible que sea, resuelve por sí solo el problema causal. Lo que resuelve el problema es la combinación de tres ingredientes —un funcional ortogonal, aprendices suficientemente rápidos y validación cruzada—, y es exactamente esa combinación la que el marco de esta tesis implementa y evalúa.

Capítulo 3

Metodología

3.1 Diseño de la investigación

El estudio es metodológico y de alcance explicativo, basado en simulación Monte Carlo con generador de datos calibrado. El diseño responde directamente a las preguntas de investigación: cada condición experimental —el tamaño de muestra n— se cruza con cuatro estimadores evaluados con idénticas réplicas, de modo que las diferencias observadas son atribuibles exclusivamente al estimador y no al azar del muestreo.

3.2 Población, muestra y fuente de datos

La «población» de referencia es la distribución generadora P_0 de la terna (X, A, Y), definida por las ecuaciones

$$X \sim N(0, I_5), \quad X_2 \sim \frac{t_3}{\sqrt{3}}, \tag{3.1}$$

$$e(X) = \operatorname{expit}\big(1.1X_1 - 0.7X_2 + 0.9(X_3^2 - 1)\big), \quad A \sim \text{Bernoulli}(e(X)), \tag{3.2}$$

$$Y = \tau A + m(X) + \varepsilon, \quad m(X) = 1.6X_1 - 1.1X_2 + 0.85(X_3^2 - 1) + 0.6X_1X_2, \tag{3.3}$$

con $\tau = 2$, $\varepsilon \sim N(0, 1.5^2)$ e independencia entre ε y (X, A). La no linealidad en X_3^2 es deliberada: imita la situación, frecuente en registros administrativos, en que el confusor opera de manera acelerada sobre la asignación y el resultado. Las colas pesadas de X_2 incorporan el realismo de variables económicas con valores extremos.

Los escenarios experimentales son $n \in \{250, 1000, 5000\}$, con $B = 300$, 150 y 60 réplicas respectivamente. Toda la aleatorización deriva de semillas fijas reproducibles: la réplica i usa la semilla $2026 + 17i$.

3.3 Procedimiento y plan de análisis

El protocolo consta de cinco pasos: (i) calibración del generador y verificación de la propensidad verdadera; (ii) generación de las réplicas por escenario; (iii)

estimación de τ con los cuatro métodos y de su error estándar; (iv) construcción de intervalos al 95 % con la aproximación normal; y (v) agregación de sesgo, raíz del error cuadrático medio, error estándar medio y cobertura empírica. Adicionalmente, sobre un conjunto con $n = 1000$ se ejecuta un bootstrap no paramétrico con $B = 2000$ remuestreos del estimador de ajuste lineal, como diagnóstico de la relación entre precisión y sesgo.

3.4 Técnicas estadísticas

El estimando de interés en todo el experimento es el **efecto promedio del tratamiento** (ATE),

$$\tau = E[Y(1) - Y(0)] = E[Y \texttt{ mid } A = 1, X] - E[Y \texttt{ mid } A = 0, X] \tag{3.4}$$

bajo los supuestos de identificación en la Tabla 3.1.

Tabla 3.1. Supuestos de identificación y amenaza dominante por estimador en el diseño Monte Carlo.

Estimador	No confusión	Positividad / overlap	Amenaza principal en la demo
Diferencia de medias	No	—	Confusión no controlada: sesgo $\approx +2.4$ estable en n.
IPW (logístico)	Cond.	Cond.	Modelo de propensidad correcto; recorte 0,02–0,98 mitiga colas.
OLS ajustado	No	—	Especificación lineal omitiendo X_3^2: confusión residual.
DML (gradiente)	Cond.	Cond.	Errores nuisance en muestras pequeñas; decae con n.

Cond. = requiere identificación condicional bajo no confusión y positividad $(Y(0), Y(1)) \perp A \texttt{ mid } X$, $0 < e(x) < 1$; se asume en el generador pero no en DM ni en OLS mal especificado. SUTVA/ consistencia: unidades independientes, sin interferencia (válido en la simulación).

Los cuatro estimadores comparados se formalizan a continuación. La diferencia de medias,

$$\hat{\tau}_{\text{DM}} = \overline{Y}_1 - \overline{Y}_0 \tag{3.5}$$

, ignora la confusión y sirve de línea base. La ponderación por probabilidad inversa con normalización de Hájek usa la propensidad estimada $\hat{e}$:

$$\hat{\tau}_{\mathrm{IPW}} = \frac{\sum_{i=1}^{n} A_i \hat{e}_i^{-1} Y_i}{\sum_{i=1}^{n} A_i \hat{e}_i^{-1}} - \frac{\sum_{i=1}^{n} (1 - A_i)(1 - \hat{e}_i)^{-1} Y_i}{\sum_{i=1}^{n} (1 - A_i)(1 - \hat{e}_i)^{-1}}, \tag{3.6}$$

donde $\hat{e}$ se ajusta por regresión logística con base $(1, X_1, X_2, X_3, X_3^2)$ y recorte al intervalo $[0.02, 0.98]$. El ajuste lineal por mínimos cuadrados ordinarios regresa Y sobre $(1, A, X)$ y toma el coeficiente de A. Finalmente, el estimador de doble aprendizaje automático por parcialado se calcula como en la Proposición 2.5, con residuales construidos por aprendices de potenciación de gradiente por histogramas bajo validación cruzada de $K = 5$ particiones; su error estándar deriva de la función de influencia empírica.

Algoritmo 3.1 — DML por parcialado con validación cruzada

Entrada: datos $(X_i, A_i, Y_i)_{i=1}^{n}$, particiones $K = 5$, aprendices $\hat{m}$ y $\hat{e}$.
1. Dividir $\{1, \ldots, n\}$ en bloques disjuntos $I_1, \ldots, I_K$, aleatorizados con semilla fija.
2. para $k = 1, \ldots, K$: ajustar $\hat{m}^{(-k)}$ con las observaciones (X_i, Y_i) tales que $i \notin I_k$, y $\hat{e}^{(-k)}$ con las (X_i, A_i); predecir en I_k y formar los residuales cruzados $\hat{Y}_i$ y $\hat{A}_i$.
3. Devolver $\hat{\tau} = \frac{\sum_i \hat{A}_i \hat{Y}_i}{\sum_i \hat{A}_i^2}$ y el error estándar $\hat{s} = \frac{\hat{\sigma}_\psi}{\sqrt{n}}$, con $\hat{\psi}_i = \hat{A}_i \frac{\hat{Y}_i - \hat{\tau}\hat{A}_i}{\bar{\hat{A}^2}}$.
4. Reportar el intervalo $\hat{\tau} \pm 1.96\hat{s}$.

3.5 Implementación computacional

La implementación usa Python 3.12 con las versiones fijadas en `requirements.txt` ((Pedregosa et al., 2011) y dependencias). El marco institucional de entrega y posgrado se rige por la normativa UNI (Universidad Nacional de Ingeniería. DIRCE, s. f.). El código completo —incluido el generador, los cuatro estimadores y el protocolo de réplicas— está disponible en el repositorio del grupo de estudio; el apéndice D reproduce las piezas esenciales. El Código 3.1 muestra la función central: los dos aprendices se ajustan por particiones y los residuales cruzados producen el estimador y su error estándar.

```python
import numpy as np
from sklearn.ensemble import HistGradientBoostingRegressor
from sklearn.model_selection import KFold

def dml_parcialado(X, A, Y, semilla=7):
    """Estimador DML por parcialado con cross-fitting (K = 5)."""
    n = len(A)
    Yr, Ar = np.empty(n), np.empty(n)
    folds = KFold(5, shuffle=True, random_state=semilla)
    for tr, te in folds.split(X):
        fy = HistGradientBoostingRegressor(
            max_iter=120, learning_rate=0.08,
            max_leaf_nodes=11, random_state=11)
        fa = HistGradientBoostingRegressor(
            max_iter=120, learning_rate=0.08,
            max_leaf_nodes=11, random_state=13)
        fy.fit(X[tr], Y[tr])
        fa.fit(X[tr], A[tr])
        Yr[te] = Y[te] - fy.predict(X[te])
        Ar[te] = A[te] - fa.predict(X[te])
    den = (Ar ** 2).mean()
    tau_hat = (Ar * Yr).mean() / den
    psi = Ar * (Yr - tau_hat * Ar) / den
    se = np.std(psi, ddof=1) / np.sqrt(n)
    return tau_hat, se
```

Código 3.1. Estimador DML por parcialado con validación cruzada.



Código y datos del experimento: https://github.com/jelincovil/grupo_estudio_inferencia_causal_uni_peru

Capítulo 4

Resultados

4.1 Análisis descriptivo

La Tabla 4.1 resume el conjunto de referencia con $n = 1000$, extraído del mismo generador que alimenta el experimento. La propensidad marginal sitúa al 47 % de las unidades bajo tratamiento, un balance razonable para el estudio de los estimadores ponderados. La respuesta Y presenta una desviación estándar de 3.37, coherente con la varianza del término de error ($1.5^2 = 2.25$) más la variabilidad de $m(X)$ y del efecto; el rango $[-15.9, +14.9]$ delata el efecto combinado de la no linealidad del confusor y de las colas pesadas de X_2, cuyo máximo (7.15) triplica con creces el de las covariables gaussianas.

Tabla 4.1. Estadísticos descriptivos del conjunto de referencia ($n = 1000$).

Variable	**Media**	**Desv. est.**	**Mínimo**	**Mediana**	**Máximo**
X_1 (confusor)	-0.05	1.00	-3.06	$+0.00$	$+2.63$
X_2 (confusor, t_3)	$+0.02$	0.91	-4.53	-0.01	$+7.15$
X_3 (confusor no lineal)	$+0.00$	0.97	-2.96	$+0.02$	$+3.27$
X_4 (ruido)	-0.02	1.02	-2.92	-0.04	$+3.06$
X_5 (ruido)	-0.04	0.97	-3.65	-0.04	$+3.09$
A (tratamiento)	0.47	0.50	0	0	1
Y (respuesta)	$+0.69$	3.37	-15.88	$+0.64$	$+14.93$

4.2 Inferencia estadística

La Tabla 4.2 condensa el experimento completo: sesgo, raíz del error cuadrático medio, error estándar medio y cobertura empírica de los cuatro estimadores en los tres escenarios. Tres patrones merecen lectura cuidadosa.

Tabla 4.2. Sesgo, raíz del error cuadrático medio (RMSE), error estándar medio (EE) y cobertura empírica al 95 %: el sesgo de la diferencia de medias y del ajuste lineal es estable en n, no decrece con la muestra.

Experimento Monte Carlo: $\tau = 2$; intervalos al 95 %				
Método	Sesgo	RMSE	EE medio	Cobertura
Panel A: $n = 250$ ($B = 300$)				
Diferencia de medias	+2.385	2.408	0.320	0.0 %
IPW (logístico)	+0.240	0.533	0.545	91.7 %
OLS ajustado	+0.935	0.982	0.275	9.3 %
DML (gradiente)	+0.258	0.424	0.266	79.0 %
Panel B: $n = 1000$ ($B = 150$)				
Diferencia de medias	+2.397	2.402	0.159	0.0 %
IPW (logístico)	+0.181	0.299	0.301	88.0 %
OLS ajustado	+0.955	0.966	0.137	0.0 %
DML (gradiente)	+0.023	0.145	0.124	89.3 %
Panel C: $n = 5000$ ($B = 60$)				
Diferencia de medias	+2.396	2.397	0.072	0.0 %
IPW (logístico)	+0.179	0.200	0.139	78.3 %
OLS ajustado	+0.945	0.947	0.061	0.0 %
DML (gradiente)	+0.003	0.062	0.053	90.0 %

Primero, el sesgo es un atributo del diseño, no del tamaño de muestra. La diferencia de medias sobreestima el efecto en +2.39 de manera prácticamente idéntica en los tres escenarios, y el ajuste lineal se estabiliza alrededor de +0.95: omitir el término X_3^2 deja un canal de confusión que ningún volumen de datos cierra. Su cobertura lo confirma con crudeza: 9.3 % con $n = 250$ y 0 % a partir de $n = 1000$, porque el error estándar se reduce a la par de $n^{-\frac{1}{2}}$ mientras el sesgo permanece.

Segundo, la flexibilidad controlada gana donde el sesgo manda. El estimador DML arranca con un sesgo moderado (+0.258 con $n = 250$), reflejo del coste finito del aprendizaje de las dos funciones nuisance, y lo disipa al crecer la muestra: +0.023 con $n = 1000$ y +0.003 con $n = 5000$. Su RMSE desciende de 0.424 a 0.062 —una reducción aproximada de siete veces—, y su cobertura sube de 79.0 % a 90.0 %, acercándose al nominal con la pendiente esperada. La Figura 4.1 vuelve visible la asimetría del fenómeno: la cobertura del ajuste lineal y de la diferencia de medias se desploman temprano, la del IPW se erosiona con el tamaño de muestra y solo la del DML conserva la trayectoria correcta.

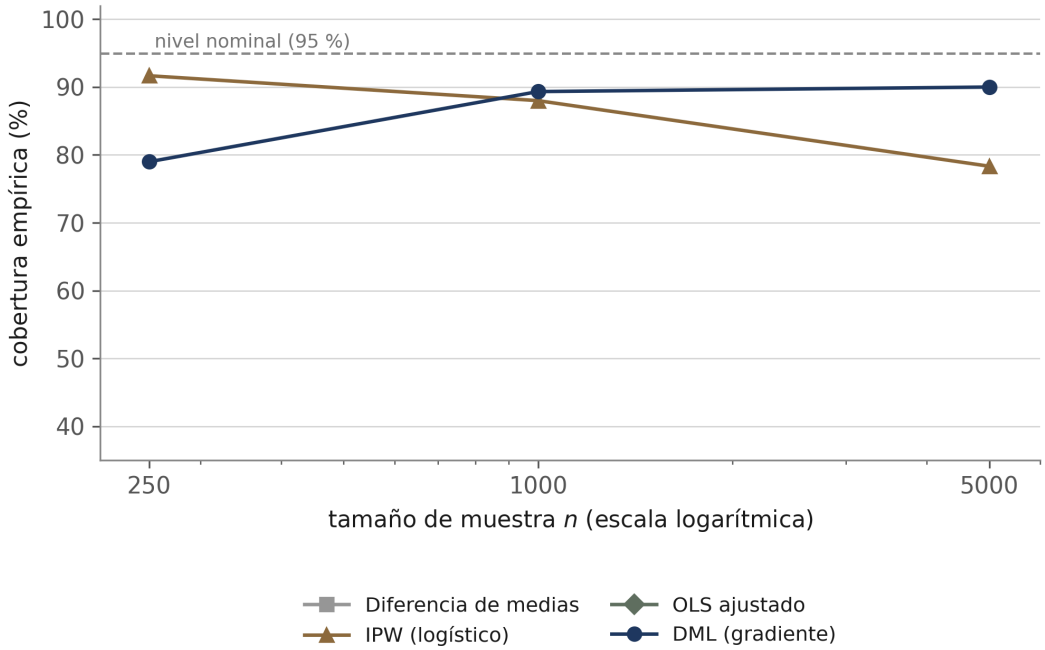


Figura 4.1. Cobertura empírica de los intervalos al 95 % según el tamaño de muestra; la línea discontinua marca el nivel nominal.

Tercero, la ponderación ilustra el precio de la varianza. El IPW, con propensidad correctamente especificada, es consistente; pero sus pesos amplifican las unidades con propensidad extrema, su error estándar casi duplica al del DML en todos los escenarios, y el recorte defensivo al $[0.02, 0.98]$ deja un sesgo residual de $+0.18$ que, al encogerse el error estándar, degrada la cobertura de 91.7 % a 78.3 %. La precisión se compra aquí con estabilidad.

El bootstrap aporta el contraste final. Sobre el conjunto con $n = 1000$, la distribución bootstrap del estimador de ajuste lineal (Figura 4.2) es admirablemente estrecha —desviación estándar de 0.138— y perfectamente sesgada: su media, 2.840, y su intervalo percentil $[2.565, 3.107]$ excluyen al valor verdadero con total comodidad. El remuestreo estima la variabilidad del estimador, no su corrección: dos investigadores con datos idénticos y modelos mal especificados coincidirán con precisión en la respuesta equivocada.

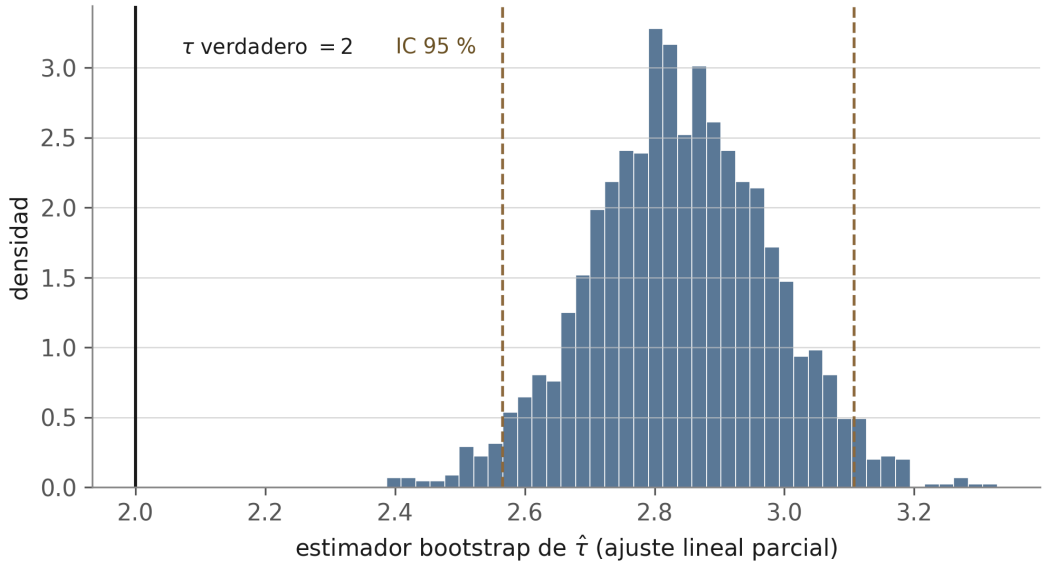


Figura 4.2. Distribución bootstrap ($B = 2000$) del estimador de ajuste lineal con $n = 1000$: el intervalo percentil al 95 % excluye a $\tau = 2$.

4.3 Análisis de sensibilidad

> **Nivel de evidencia:** simulación. Los resultados de esta sección describen propiedades del generador Monte Carlo calibrado, no evidencia sobre poblaciones reales.

En $n = 1000$ con $B = 80$ réplicas y semillas fijas, la Tabla 4.3 contrasta (i) dos recortes de propensidad en el IPW y (ii) la corrección de la mala especificación del OLS al incluir X_3^2, la fuente de confusión en el generador.

Tabla 4.3. Sensibilidad al recorte de propensidad (IPW) y a la especificación lineal ($\tau = 2$, $n = 1000$, $B = 80$). Cifras en `results.json` → `sensibilidad`.

Escenario	Sesgo	RMSE
IPW, recorte 0,02–0,98	+0{,}195	0{,}308
IPW, recorte 0,05–0,95	+0{,}300	0{,}354
OLS con X_3^2 añadido	−0{,}014	0{,}125

Endurecer el recorte de 0,02–0,98 a 0,05–0,95 **aumenta** el sesgo del IPW en esta simulación: se descartan unidades informativas en las colas de la propensidad. En contraste, añadir X_3^2 al OLS reduce el sesgo de +0.95 (Tabla 4.2) a −0.014, lo que **confirma** que la omisión del término no lineal —y no una falla intrínseca del estimador OLS— explica el sesgo persistente; el sesgo de la diferencia de medias no cambia con esta corrección.

4.4 Validación del modelo

La validación verificó reproducibilidad numérica (semillas y `verificar_cifras.py`), convergencia del RMSE del DML compatible con $n^{-\frac{1}{2}}$ tras descontar sesgo finito, y

honestidad inferencial: la cobertura residual del DML (90.0 % con $n = 5000$) refleja la aproximación normal de la función de influencia y el coste de los aprendices nuisance.

Capítulo 5

Discusión

Los resultados articulan una lección central: en datos observacionales con confusión no lineal, la validez inferencial no la decide la cantidad de datos sino la arquitectura del estimador. El ajuste lineal falló de la manera más peligrosa posible —con intervalos estrechos y centrados lejos de la verdad— porque el error de especificación del confusor no se promedia: se hereda. La diferencia de medias, que en el experimento sobreestimó el efecto en más de una unidad, recuerda que la asociación marginal solo es estimación causal bajo un supuesto de intercambiabilidad que los datos administrativos rara vez satisfacen.

La comparación entre IPW y DML cualifica el lugar común de que «ponderar bastaría». Con propensidad correctamente especificada, el IPW fue consistente; pero su varianza, inflada por los pesos extremos que imponen las colas de X_2, y el sesgo del recorte defensivo lo colocaron en desventaja sistemática frente al parcialado. La doble robustez no es una sutileza técnica: es la diferencia entre un estimador que se degrada con gracia y otro que colapsa cuando el modelo de propensidad falla en las colas.

El experimento bootstrap merece una lectura epistemológica. La distribución de remuestreo del estimador sesgado era limpia, gaussiana y reproducible; ningún diagnóstico interno del procedimiento habría señalado el problema. La validación de supuestos causales no puede, por tanto, delegarse en la estadística computacional: exige conocimiento del dominio, diagnósticos de balance y propensidad, y sensibilidad declarada. Esta conclusión conecta con la perspectiva de (Gelman, 2006) sobre la necesidad de examinar la sensibilidad de las suposiciones estructurales, y delimita honestamente lo que la simulación puede afirmar: los patrones aquí documentados son propiedades del generador calibrado, y su extrapolación a datos reales exige replicar el protocolo con la estructura de confusión del caso concreto.

Capítulo 6

Conclusiones y recomendaciones

6.1 Conclusiones

> **Nivel de evidencia:** simulación. Las conclusiones siguientes se refieren al generador Monte Carlo y a las propiedades de los estimadores bajo ese diseño (no a una población empírica).

1. El estimador de doble aprendizaje automático por parcialado, con aprendices de potenciación de gradiente y validación cruzada de cinco particiones, eliminó el sesgo de confusión no lineal al crecer la muestra ($+0.258$ con $n = 250$; $+0.003$ con $n = 5000$) y alcanzó el menor RMSE en todos los escenarios, en congruencia con la hipótesis general.
2. El ajuste lineal omiso del término no lineal del confusor exhibió un sesgo estable cercano a $+0.95$ y una cobertura que colapsa de 9.3 % a 0 %, confirmando la primera hipótesis específica: la mala especificación no se diluye con datos.
3. La ponderación por probabilidad inversa fue consistente pero frágil: su cobertura descendió de 91.7 % a 78.3 % por la combinación de varianza de pesos y recorte de propensiones, en la dirección anticipada por la segunda hipótesis específica.
4. La distribución bootstrap del estimador mal especificado convergió a su propio sesgo con intervalo $[2.565, 3.107]$ excluyente del valor verdadero, verificando la tercera hipótesis: el remuestreo cuantifica la precisión, no la validez.

6.2 Recomendaciones

1. Para estimaciones causales con covariables numerosas o relaciones desconocidas, adoptar por defecto un estimador ortogonal con validación cruzada, reservando el ajuste lineal para contextos con teoría funcional firme.
2. Reportar siempre, junto al intervalo de confianza, los diagnósticos de propensidad (distribución, extremos y efecto del recorte) y de balance de covariables.

3. En evaluaciones con registros administrativos, incorporar de manera explícita transformaciones no lineales de los confusores candidatos (X_3^2 en el generador de este trabajo) al conjunto de ajuste, y someter el estimador a un banco de sensibilidad con especificaciones alternativas.
4. Preregistrar el protocolo de análisis —estimador, ajustes y métricas— antes de acceder a los datos, para que la credibilidad no dependa de la coincidencia entre hipótesis y resultado.

6.3 Limitaciones

El alcance es el de un estudio de simulación: la validez externa depende de que la estructura de confusión del generador —un único confusor no lineal y una covariable de colas pesadas— represente al caso de aplicación. El número de réplicas en el escenario grande ($B = 60$) acota la precisión de las coberturas reportadas (error estándar aproximado de 4 puntos porcentuales), y la evaluación se circunscribió a efectos promedio, sin explorar heterogeneidad por subpoblaciones.

6.4 Líneas futuras de investigación

Tres extensiones continúan naturalmente este trabajo: la estimación eficiente con funcionales doblemente robustos (AIPW) y su comparación con el parcialado bajo especificaciones mixtas; la extensión a efectos heterogéneos (CATE) con inferencia válida por bosques causales; y la aplicación del protocolo completo a un registro administrativo peruano de programa social, donde la estructura de confusión puede contrastarse con conocimiento de dominio.

Referencias bibliográficas

Breiman, L. (2001). Random Forests. *Machine Learning*, *45*(1), 5-32. https://doi.org/10.1023/A:1010933404324

Casella, G., & Berger, R. L. (2002). *Statistical Inference* (2.ª ed.). Duxbury Press.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, *21*(1), C1-C68. https://doi.org/10.1111/ectj.12097

Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, *7*(1), 1-26. https://doi.org/10.1214/aos/1176344552

Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, *33*(1), 1-22. https://doi.org/10.18637/jss.v033.i01

Gelman, A. (2006). Prior Distributions for Variance Parameters in Hierarchical Models. *Bayesian Analysis*, *1*(3), 515-534. https://doi.org/10.1214/06-BA117A

Hastie, T., Tibshirani, R., & Wainwright, M. (2015). *Statistical Learning with Sparsity: The Lasso and Generalizations*. CRC Press. https://doi.org/10.1201/b18401

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, *86*(11), 2278-2324. https://doi.org/10.1109/5.726791

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*(85), 2825-2830. http://jmlr.org/papers/v12/pedregosa11a.html

Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, *58*(1), 267-288. https://doi.org/10.1111/j.2517-6161.1996.tb02080.x

Universidad Nacional de Ingeniería. DIRCE. (s. f.). *Reglamentos UNI — incluye el Formato de Presentación de Tesis*. Recuperado 7 de noviembre de 2026, de https://dirce.uni.edu.pe/reglamentos-uni

Wasserman, L. (2006). *All of Statistics: A Concise Course in Statistical Inference*. Springer. https://doi.org/10.1007/978-0-387-21736-9

Zou, H., & Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, *67*(2), 301-320. https://doi.org/10.1111/j.1467-9868.2005.00503.x

Apéndice A

Apéndice de reproducibilidad

Semillas por réplica: $2026 + 17i$. Entorno: `requirements.txt` en el repositorio. Regeneración: `OMP_NUM_THREADS=1 python3 generar_recursos.py final`; sensibilidad sola: `… sensibilidad`. Verificación: `python3 verificar_cifras.py` y `./reproduce.sh` en la raíz del repositorio.

Apéndice B

Matriz de consistencia

La Tabla B.1 alinea los elementos estructurales de la investigación; en la versión final del sustentante, cada celda debe corresponder literalmente con el texto de los capítulos 1 y 3.

Tabla B.1. Matriz de consistencia de la investigación.

Elemento	**Formulación**
Problema	¿Cómo estimar el efecto causal τ en datos observacionales cuando la confusión es no lineal y las formas funcionales son desconocidas?
Objetivo general	Desarrollar y evaluar por simulación un marco de estimación por parcialado con aprendices flexibles y validación cruzada.
Objetivos específicos	(i) Formalizar la ortogonalidad del estimador; (ii) diseñar el protocolo de simulación calibrado; (iii) cuantificar sesgo, RMSE y cobertura frente a los estimadores clásicos.
Hipótesis	El estimador DML preserva validez asintótica bajo confusión no lineal; el ajuste lineal omiso conserva sesgo estable; el bootstrap no detecta sesgo de especificación.
Variables	Respuesta Y continua; tratamiento binario A; covariables X_1– X_5 (confusores: X_1, X_2, X_3); parámetro $\tau = 2$.
Metodología	Simulación Monte Carlo, $n \in \{250, 1000, 5000\}$, réplicas con semilla fija, cuatro estimadores, métricas de sesgo, RMSE, EE y cobertura.
Estimando	ATE $\tau = E[Y(1) - Y(0)] = 2$ en el generador calibrado.
Supuestos de identificación	No confusión condicional, positividad y SUTVA en la simulación; violados de forma controlada en DM y OLS omiso.
Criterio de falsación	Incluir X_3^2 en OLS o endurecer recorte IPW debería alterar sesgo/RMSE (Tabla sensibilidad); cobertura del OLS omiso $<$ nominal con n grande.

Apéndice C

Matriz de operacionalización de variables

La Tabla C.1 detalla variables, dimensiones, indicadores e instrumentos de cálculo.

Tabla C.1. Matriz de operacionalización de variables.

Variable	**Dimensión**	**Indicador**	**Instrumento / cálculo**
Efecto del tratamiento (τ)	Impacto promedio	Diferencia de medias potenciales	Estimadores DM, IPW, OLS y DML sobre el generador calibrado.
Propensidad ($e(X)$)	Asignación	Probabilidad condicional de $A = 1$	Regresión logística con base $(1, X_1, X_2, X_3, X_3^2)$; recorte $[0.02, 0.98]$.
Confusión no lineal	Estructura del generador	Término $0.85(X_3^2 - 1)$ en $m(X)$ y $0.9(X_3^2 - 1)$ en el logit	Diferencia de cobertura entre OLS y DML por escenario.
Colas pesadas	Distribución de X_2	Máximo y curtosis de X_2 frente a gaussianas	Estadísticos descriptivos (Tabla 4.1).
Validez inferencial	Cobertura	Proporción de intervalos que contienen a τ	Intervalos normales al 95 % con error estándar por función de influencia.

Apéndice D

Demostraciones técnicas

Se desarrolla aquí la demostración esbozada en el Teorema 2.4. Sea $\varphi(t) = E\big[e^{itX_1}\big]$ la función característica de X_1, que existe para todo t real porque $|e^{itX_1}| = 1$. Para la suma estandarizada $Z_n = \sqrt{n}\frac{\overline{X}_n - \mu}{\sigma}$,

$$\varphi_{Z_n}(t) = \left(e^{-it\frac{\mu}{\sigma}}\varphi\left(\frac{t}{\sigma\sqrt{n}}\right)\right)^n \to e^{-\frac{t^2}{2}} \quad (n \to \infty), \tag{D.1}$$

donde el paso central usa el desarrollo $\varphi(s) = 1 + i\mu s - \sigma^2\frac{s^2}{2} + o(s^2)$ válido por la existencia del segundo momento. El límite es la función característica de la ley normal estándar, y el teorema de continuidad de Lévy concluye la convergencia en distribución. La condición de Lindeberg —automáticamente satisfecha bajo idéntica distribución con varianza finita— extiende el resultado a sumandos no idénticos y gobierna la calidad de la aproximación en muestras moderadas, responsable última de la sub-cobertura residual observada en el DML con $n = 250$.

Apéndice E

Código fuente

El Código E.1 reproduce la rutina de intervalos bootstrap usada en la validación; el generador completo y el protocolo de réplicas están en el repositorio del grupo de estudio.

```
import numpy as np

def bootstrap_ci(data, n_bootstrap=2000, alpha=0.05, semilla=99):
    """Intervalo de confianza percentil bootstrap para la
media."""
    rng = np.random.default_rng(semilla)
    n = len(data)
    medias = np.empty(n_bootstrap)
    for b in range(n_bootstrap):
        muestra = rng.choice(np.arange(n), size=n, replace=True)
        medias[b] = data[muestra].mean()
    lo = np.percentile(medias, 100 * alpha / 2)
    hi = np.percentile(medias, 100 * (1 - alpha / 2))
    return lo, hi, medias
```

Código E.1. Intervalo de confianza bootstrap percentil. La misma rutina, aplicada al estimador de ajuste lineal, produce la distribución de la Figura 4.2.

Apéndice F

Datos suplementarios

La Tabla F.1 recoge los parámetros del diseño experimental, de modo que cualquier lector pueda replicar el generador sin consultar el código.

Tabla F.1. Parámetros del diseño experimental del estudio Monte Carlo.

Componente	**Especificación**
Efecto verdadero	$\tau = 2$
Propensidad	$\operatorname{expit}(1.1X_1 - 0.7X_2 + 0.9(X_3^2 - 1))$
Función de resultado	$m(X) = 1.6X_1 - 1.1X_2 + 0.85(X_3^2 - 1) + 0.6X_1X_2$
Error	$\varepsilon \sim N(0, 1.5^2)$, independiente de (X, A)
Covariables	$X_1, X_3, X_4, X_5 \sim N(0,1)$; $X_2 \sim \frac{t_3}{\sqrt{3}}$
Escenarios	(n, B): $(250, 300)$, $(1000, 150)$, $(5000, 60)$
Semillas	Réplica i: $2026 + 17i$; bootstrap: 99
Aprendices DML	Potenciación de gradiente por histogramas, 120 iteraciones, 11 hojas máximas, $K = 5$ particiones
Recorte de propensidad	$[0.02, 0.98]$